Mushrooms Classification

Data Processing and Analysis 2025/2026 - Project group work of:

Paninforni Filippo,
Belingheri Diego,
Guainalia Alejandro,
Buonanno Marco.

Classificazione di funghi: analisi e modelli predittivi

Progetto di **Data Processing and Analysis** sul dataset **Agaricus Lepiota** (UCI Machine Learning Repository): 8.124 campioni, 22 variabili categoriche morfologiche.

Obiettivo: distinguere funghi **edibili** da **velenosi** con tecniche di EDA, selezione delle feature e confronto di sei algoritmi di classificazione.

Dataset: 8.000+ funghi analizzati

Abbiamo analizzato oltre 8.000 campioni di funghi per distinguere quelli edibili da quelli velenosi.
I dati includono 22 caratteristiche morfologiche osservabili.

Caratteristiche Osservate

- **Forma e colore del cappello**
- **Odore e ammaccature**
- **Caratteristiche delle lamelle**
- **Forma e colore del gambo**
- **Colore delle spore e habitat**

Numeri Chiave

- **8.124 campioni** analizzati
- **22 caratteristiche morfologiche**
- Dataset perfettamente bilanciato: **52% edibili**, **48% velenosi**
- Tutti i dati sono osservazioni qualitative (colori, forme, odori)

Preprocessing

I dati sono stati raccolti con buona prassi, perciò il dataset non ha avuto bisogno di manipolazioni importanti; in particolare sono state eseguite:

- Missing detection e MCAR test
- Rimozione delle variabili con bassa variabilità
- Test delle contingenze
- One hot encoding
- Split in train e test set

Qualità dei dati

Dati mancanti

L'unica variabile con dati mancanti é 'stalk_root' con ben 2480 valori '?'.

Eseguendo un controllo tramite MCAR test i missing risultano influenzati dai valori delle altre variabili.

La variabile 'stalk_root' deve essere mantenuta poichè i dati '?' contengono informazioni

Bassa variabilità

La variabilità dei predittori é stata controllata tramite il gini normalizzato, una misura per valutare l'eterogeneità dei dati.

Incrociando i risultati ottenuti con le frequenze delle classi dominanti sono state rimosse le variabili 'veil-type', 'veil-color', 'gill-attachment' e 'ring-number'

Variabilità dei predittori e della classe

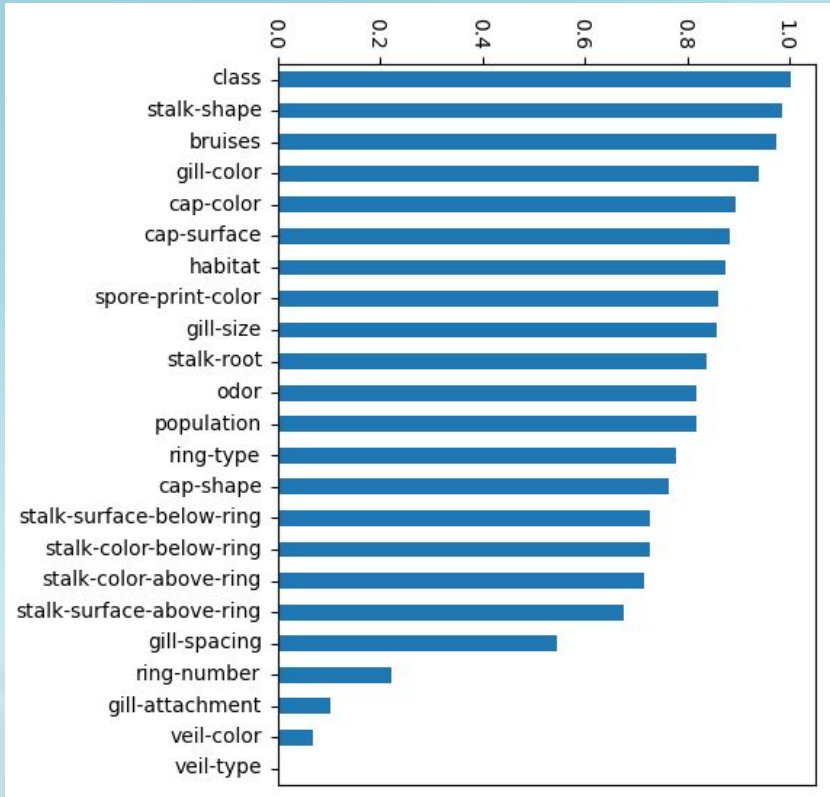

Come le caratteristiche si relazionano

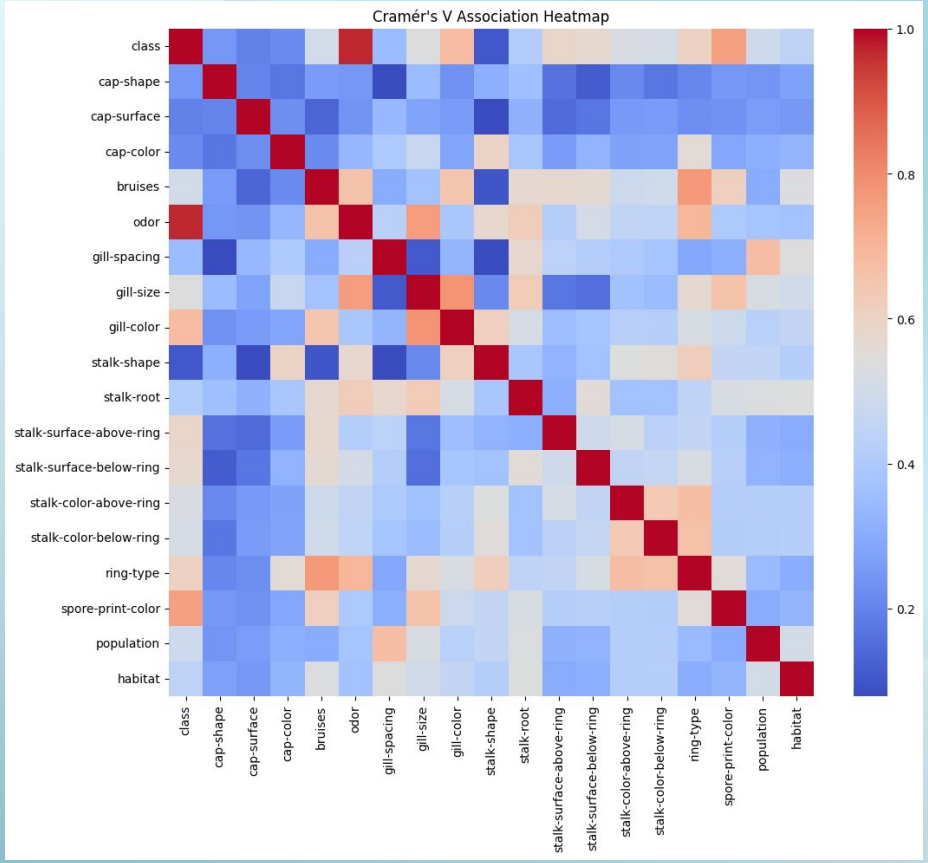

Abbiamo analizzato come le diverse caratteristiche si influenzano a vicenda. Alcune caratteristiche sono fortemente collegate, altre sono indipendenti.

L’analisi delle contingenze tramite la V di Cramer mostra che la classe é fortemente connessa con la variabile ‘odor’

Approccio alla modellazione

Nella classificazione dei funghi, **la scelta della metrica** di valutazione **è cruciale**, data l'importanza della sicurezza alimentare. Abbiamo prioritizzato la **recall** rispetto all'accuracy.

Falso Positivo

Classificare un fungo commestibile come velenoso. Questo è un errore **accettabile**, pur comportando la perdita di un fungo edibile.

Falso Negativo

Classificare un fungo velenoso come commestibile.

Questo è un errore **pericoloso** e inaccettabile.

Massimizzare la recall significa minimizzare i falsi negativi, garantendo che nessun fungo velenoso venga erroneamente classificato come commestibile. La nostra priorità è la massima **sicurezza**.

Modelli implementati

Abbiamo testato diversi algoritmi per garantire robustezza:

- Probabilistici/lineari : Naive bayes, GLM.
- Basati sulla distanza: KNN, SVM.
- Basati su alberi (sia ensemble che non): Decision Tree, Random Forest, XG Boost.

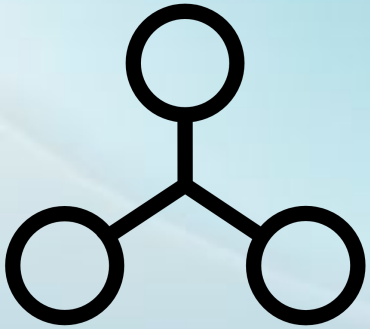

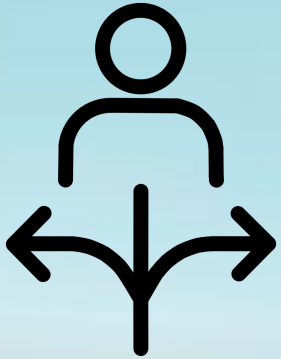

Risultati dei modelli di classificazione

Sette algoritmi valutati sul test set (2.438 campioni). Metriche principali: accuracy, precision, recall, F1-score. Ottimizzazione tramite **GridSearchCV** (5-fold CV, scoring='recall').

Modello	Accuracy	Precision	Recall	F1
Random Forest	1.000	1.000	1.000	1.000
Decision Tree	1.000	1.000	1.000	1.000
KNN (k=1)	1.000	1.000	1.000	1.000
XGBoost	1.000	1.000	1.000	1.000
SVM Lineare	1.000	1.000	1.000	1.000
Regressione Logistica	1.000	1.000	1.000	1.000
Naive Bayes	0.9442	0.9668	0.9157	0.9406

Risultato: tutti i modelli hanno prestazioni eccellenti, tranne Naive Bayes che raggiunge il 94% di accuratezza (il più basso tra i modelli testati).

Questo significa che il problema è intrinsecamente facile da risolvere con i dati che abbiamo.

Feature importance

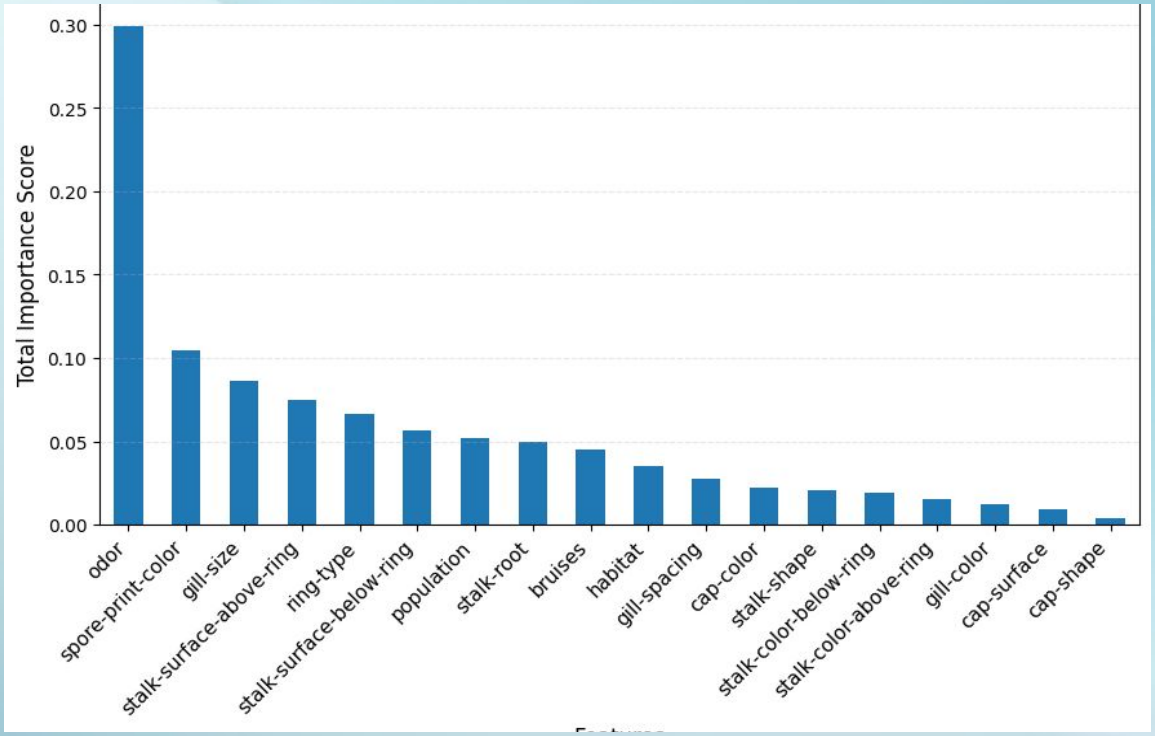

La variabile dominante: “odor”

“odor” contribuisce al **29,9%** dell'importanza totale — quasi il triplo della seconda variabile (spore-print-color, 10,6%).

- **odor_n** (nessun odore): forte indicatore di commestibilità
- La permutation importance conferma: solo **odor_n** e **gill-size_n** riducono l'accuracy se perturbate

Il ruolo cruciale di "odor"

Distribuzione del target rispetto alle categorie della variabile ‘odor’

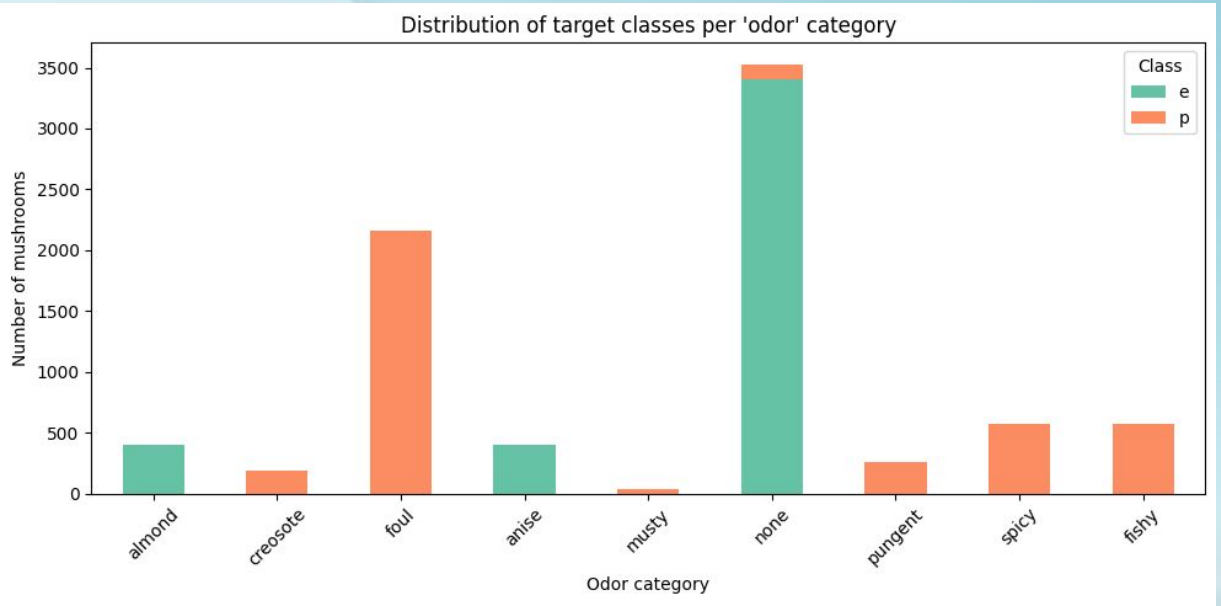

L'odore è un predittore quasi perfetto: alcune categorie sono **esclusivamente** commestibili o velenose.

- **odor_none**: ~3.400 commestibili, solo ~100 velenosi
- **odor_almond, anise**: 100% commestibili
- **odor_creosote, foul, musty, pungent, spicy, fishy**: 100% velenosi

L'odore è il miglior indicatore di commestibilità. Se un fungo non ha odore, è quasi sempre edibile.

Esperimenti ablativi: con e senza “odor”

Per quantificare il contributo di **odor**, sono stati confrontati due modelli addestrati su sottoinsiemi diversi: uno basato solo sulle informazioni legate all’odore e uno basato su tutte le altre variabili.

Solo Variabili Legate all’Odore

Random Forest — Accuracy: 98,69%

Precision: 0,99 | Recall: 0,99 | F1: 0,99

Le informazioni più utili sono risultate quelle associate all’assenza di odore, agli odori sgradevoli e ad alcune altre sfumature olfattive.

Decision Tree — Accuracy: 98,69%

Modello costruito con 7 passaggi decisionali sulle variabili legate all’odore.

Senza Variabili Legate all’Odore

Random Forest — Accuracy: 100%

Precision: 1,00 | Recall: 1,00 | F1: 1,00

Le informazioni più rilevanti emergono da caratteristiche come la forma delle lamelle, la superficie del gambo e il colore delle spore.

Decision Tree — Accuracy: 100%

Modello completo basato sulle restanti 19 variabili.

Anche il Decision Tree conferma: **solo odor** → **98,7%**, senza odor → **100%**. Il dataset è deterministicamente separabile.

Feature importance: Modello con solo variabili odor

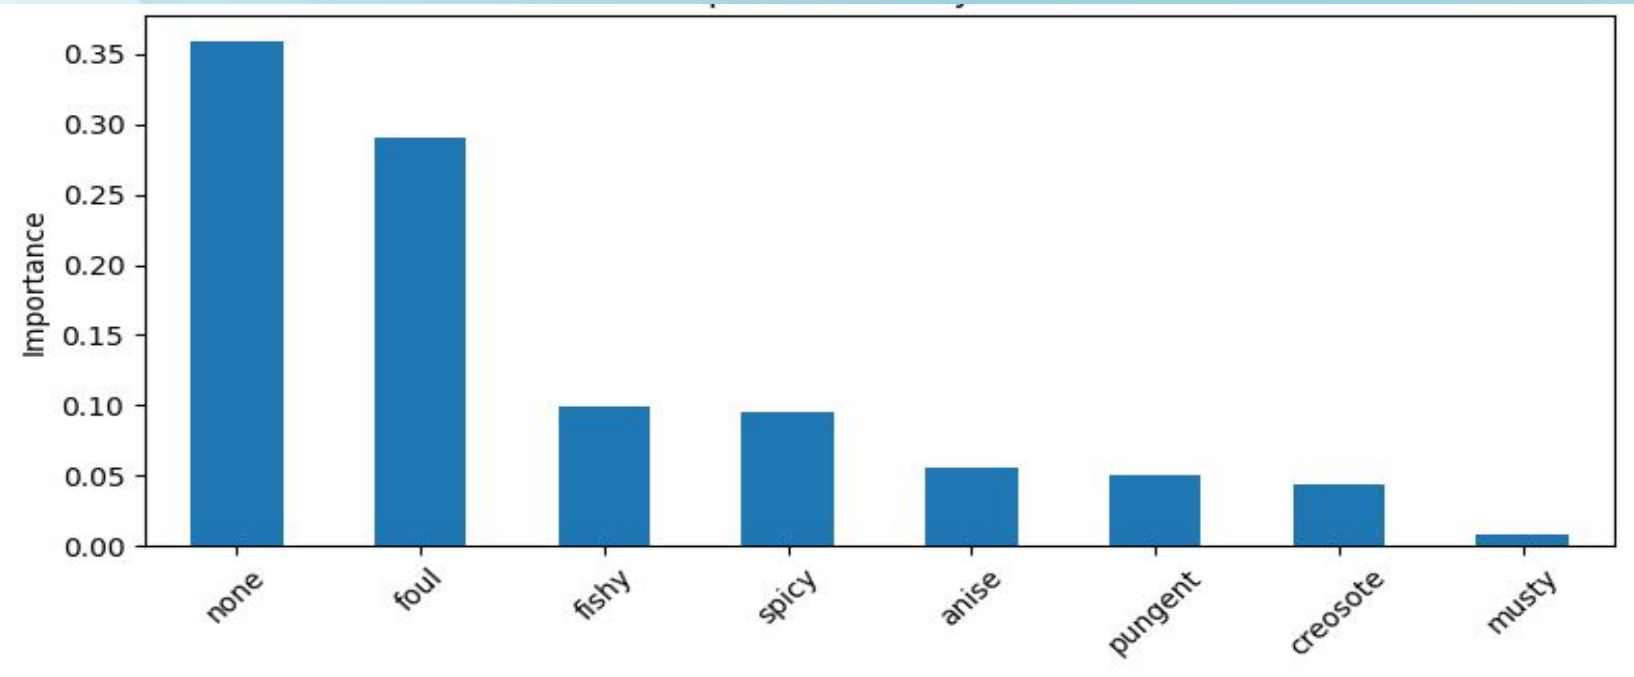

Feature importance: Modello senza variabili odor

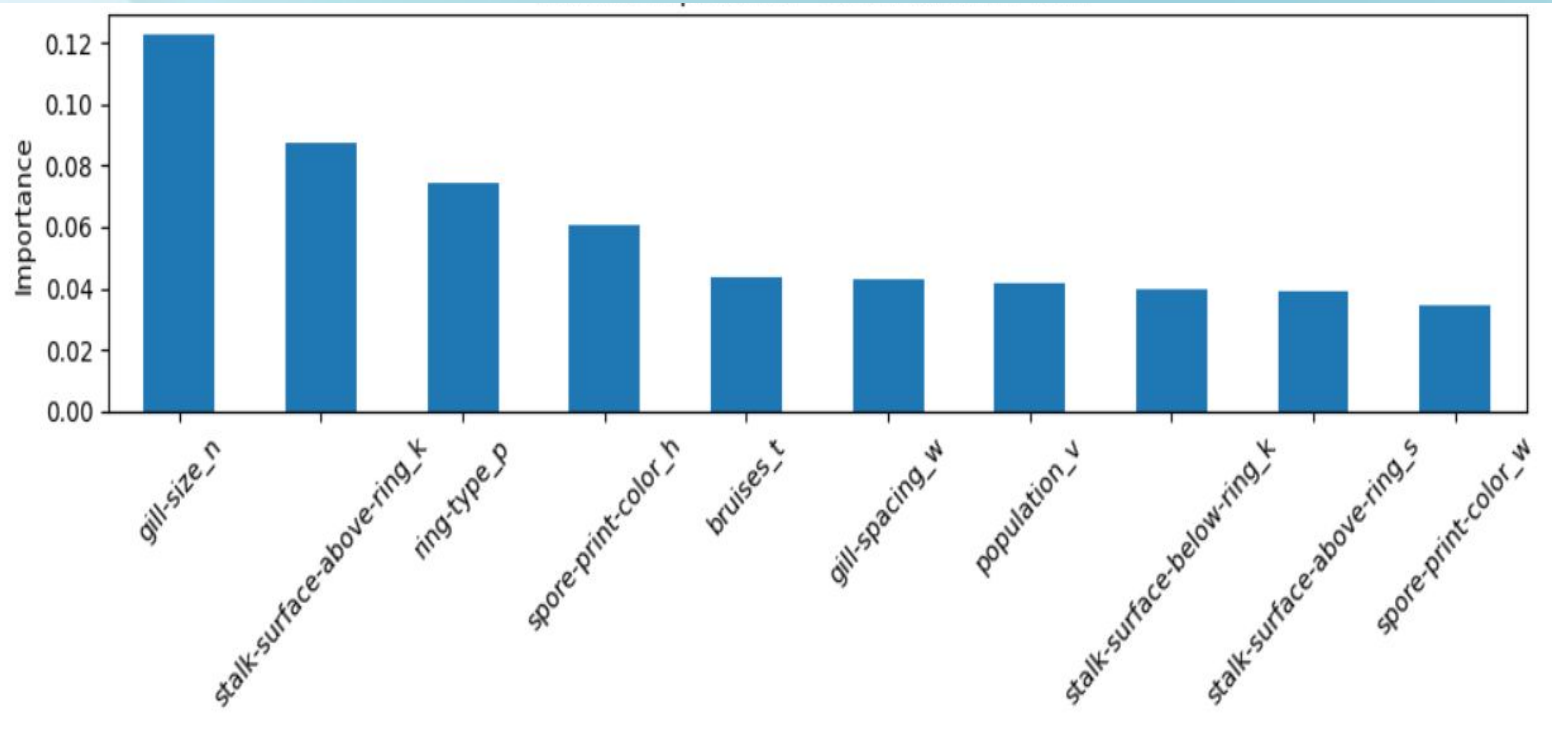

Conclusioni e riflessioni finali

1)Prestazioni eccezionali su tutti i modelli Cinque su sei modelli raggiungono accuracy perfetta (100%). Solo Naive Bayes (94,4%) mostra lievi errori. Il dataset è deterministicamente separabile.	**2)"odor" è il predittore dominante** Con ~30% dell'importanza aggregata, **odor** è la feature più potente. La distribuzione per categoria mostra separazione quasi perfetta: odore "n" → edibile, odore "k" → velenoso.
3)Ridondanza informativa nel dataset Anche senza **odor**, Random Forest e Decision Tree raggiungono il 100% di accuracy. Le feature morfologiche (gill-size, spore-print-color, stalk-surface) catturano informazione ridondante sufficiente.	**4)Qualità dei dati e preprocessing rigoroso** Il test MCAR ha rivelato che i valori “**?**” in **stalk-root** sono **informativi** (non MCAR). La rimozione di feature a varianza zero e NZV ha migliorato la qualità del dataset finale.

Grazie

per la vostra attenzione.